

# 爆紅社群文案關鍵要素——以 Threads 為例

Group 13 劉姝豆、黃浚棋、張鈞傑、卓庭榛

## Motivation and importance

在演算法主導的社群媒體生態中，資訊的擴散往往受限於平台的推薦機制與使用者的社交網路，形成「社交同溫層」的現象。然而，Meta 旗下新興平台 Threads 以簡潔的介面設計與即時互動機制，迅速吸引大量年輕用戶，尤其在台灣已達超過 240 萬使用者，成為全球使用率最高的國家，顯示其具有高度的市場滲透力與社會觀察價值。更值得注意的是，該平台上獲得大量互動的貼文，往往來自非名人帳號，顯示「素人內容」亦具備打破同溫層、引發廣泛傳播的潛力。

本研究旨在探討 Threads 平台上，哪些貼文特徵與內容風格較容易「飄出去」，亦即觀察哪些貼文觸及原有社交圈以外的使用者並獲得較高的互動表現。預計分析的變項包括：貼文長度、情緒傾向、是否使用表情符號、主題類型等。透過結合自然語言處理(NLP)技術與統計模型分析，我們期望更系統性地理解資訊在 Threads 平台上的擴散邏輯。此研究不僅有助於補足現有社群平台內容擴散研究中對 Threads 平台的不足，也具高度應用價值，可為自媒體經營者、素人創作者提供內容優化的實證建議，協助其在高競爭性的社群環境中提升觸及率與互動表現，進一步促進資訊多元化與公共討論品質的提升。

## Literature Review

### 一、社群媒體分析

過去已有諸多研究針對社群媒體上的貼文與留言進行分析，研究平台主要集中於 Twitter(現稱為 X)、Facebook 與 Instagram 等主流社交平台。根據 Singh、Halgamuge 與 Moses(2019)的系統性回顧，當前用於分析社群媒體內容的方法可大致歸納為數個類別，包括分析技術(analysis techniques)、編碼規則模型(coding rules models)、演算法(algorithms)與應用程式介面(API)操作原則等。其中，分析技術涵蓋迴歸分析(regression analysis)、社群網絡分析(social network analysis)、情緒分析(sentiment analysis)等，為目前最常見且廣泛應用的研究方法。因此，本研究亦將採用迴歸分析等相關技術作為主要的分析方法。

Singh 等人(2019)呈現過往研究中常見的分析變項。在行為層面，研究者多以貼文獲得的「按讚(likes)」、「分享(shares)」及「留言(comments)」等互動數據作為指標；在語意層面，則常見應用文字探勘與情緒分析技術；此外，Reimer(2023)研究透過 Facebook、Twitter 和 Instagram 中，20 個

全球品牌，研究結果驗證同時有圖片加文字的貼文互動率，會高於只有文字的貼文；而同時有圖片加文字的貼文，會高於同時有影片加文字的貼文，我組藉此針對 Threads 貼文特性進行探討，這些容易飄出去的貼文是否也具有以上特性。

惟鑒於 Threads 平台之使用者介面限制，本研究將聚焦於可公開獲得之變項進行分析，包括貼文內容、發文時間、按讚數、留言數、分享數、觀看次數以及作者的追蹤人數等，作為評估社群文章傳播速度之依據。

## 二、Threads 與奈米網紅

奈米網紅<sup>1</sup> (Nano Influencers) 通常被定義為擁有一千名至一萬名追蹤者的社群媒體創作者。相較於具高度知名度的名人或大型意見領袖，奈米網紅的特點在於他們的真實性與高互動性。他們往往以「鄰家朋友」的形象出現在社群中，並以生活化的語言與追隨者互動，因此更容易建立情感連結與信任感 (Jiang, 2025)。這種「小而美」的溝通方式，使奈米網紅在品牌合作與行銷推廣上展現出不同於大型網紅的優勢。

根據 Kolr 所發布的《2024 台灣網紅行銷與社群趨勢報告》指出，粉絲人數低於一萬的奈米網紅在整體創作者族群中佔比高達 68.52%，為比例最高的一群 (Kolr, 2024)。這不僅顯示社群平台生態的多元與去中心化，也反映出 Facebook、Instagram、TikTok、YouTube 等主流平台仍持續鼓勵一般用戶轉型為創作者，藉由內容創作參與平台經濟，進一步促進用戶活躍度與平台內容繁榮。

Threads 作為 Meta (Facebook 母公司) 於 2023 年推出的文字社群平台，其設計強調簡潔互動與即時溝通，迅速吸引了大量 Z 世代與年輕用戶的注意。相較於其他社群媒體，Threads 對素人創作者與奈米網紅而言門檻較低，且平台推薦機制尚處於早期階段，使得非名人帳號的貼文亦有機會獲得高度能見度與擴散效益。因此，研究奈米網紅在 Threads 上的貼文風格、互動特性與觸及效果，不僅有助於補足當前對新興社群平台的理解，也能為創作者與品牌提供策略建議。

## 三、Self-Attention 機制處理 Word embedding

隨著社群平台 (如 Flickr、Instagram 等) 成為現代人生活的一部分，是否能夠預測一篇貼文是否受歡迎對於廣告推薦、行銷策略、趨勢分析等領域都極具價值，而這些貼文中，往往有許多資訊能提供我們做模型上的訓練。過去的傳統方法通常會在加入多種 modality 與特徵後，將所有特徵視為同等重要，並以此餵入模型訓練，但此篇文獻特別針對此問題做改良，提出一種基於 Self-Attention 機制的方法，有效融合不同模態的特徵，提升預測準確度。

---

<sup>1</sup> 網紅定義是什麼？一篇詳細解析網紅意思與網紅行銷帶來的5大轉變 (<https://www.just-adtech.com/influencer-definition/>)

在語意特徵的提取中，此研究取了圖片、標籤、User ID、是否為會員、主分類、次分類等作為特徵，並將各特徵轉為文字後，再串在一起做 word embedding，而後再將此矩陣送進 self-attention 模型處理得到一個能代表此貼文的語意特徵向量。在數值特徵的提取中，此研究取了時間戳記、地理位置(經緯度)、發文頻率、分類資料長度作為特徵，並將各數值特徵做標準化的處理，並這些數值經過 MLP 提取高維特徵，此特徵向量能讓模型能理解「這筆數值資料代表什麼潛在狀態」。

最後將兩個特徵向量丟入模型訓練，並比較透過 Self-Attention 處理之特徵向量與 CNN、LSTM 等其他方式處理之特徵向量，驗證方法為看 MAE，結果亦顯現出透過 Self-Attention 處理之特徵向量餵入模型後的表現較佳。

## Data Acquisition

為了深入了解 Threads 平台中高流量貼文的擴散模式與內容特性，本研究將進行為期一週的手動資料蒐集作業。考量平台尚無開放式 API，且演算法可能根據使用者行為進行個人化推薦，因此我們計劃建立額外的小帳號，並統一操作環境，以確保所蒐集資料具備一致性與代表性。

原先的蒐集規劃如下：

- 每位組員每日擷取至少 50 篇貼文，預計可收集約 2,000 筆樣本，為後續統計分析提供足夠資料量。
- 本研究重點鎖定於奈米網紅帳號(追蹤數介於 1 千到 1 萬)所發布之內容，旨在觀察「素人」在平台中創作爆紅貼文的可能性與條件，避免名人效應對觸及率造成干擾。
- 為操作性定義「高流量」或「飄出去」的貼文，我們將觀看數達到 10,000 次以上者視為高觸及樣本，作為後續分群與模型標記依據。

但後來採用兩位教授的建議後，我們每天的爬取文章並未鎖定於鎖定於奈米網紅帳號，而是不分觀看數流量高低的爬取文章，以免自變數不顯著的狀況發生。最後我們在 2025/4/27 - 2025/5/2 期間進行資料蒐集，資料蒐集數量一共 3102 筆串文。

接著將這 3102 筆樣本用以下的時間、內容特徵、互動數據與作者特徵三大類型儲存，以下列舉出三大類型資料的細項資訊：

### 1. 時間資訊

- 發文時間(具體日期、星期幾與時段)
- 擷取當下與發文時間的相對間隔(例如「發文後第幾小時擷取」)

## 2. 內容特徵

- 貼文文字內容、字數統計(貼文長度)
- 是否有明確主題(初步人工標記, 供後續主題模型使用)
- 情緒傾向(正面、中性、負面)
- 是否包含圖片、影片、連結、Emoji、標註(@某人)、超連結等語用特徵

## 3. 互動數據與作者特徵

- 使用者互動資料:按讚數、留言數、分享數、觀看數
- 發文者追蹤人數(判斷其是否為素人帳號)

希望透過上述多層次資料蒐集, 能掌握貼文在內容表現與平台互動層面的全貌, 為後續語意分析與統計建模奠定紮實基礎。

# Predetermined Research Methodology

## 一、前處理與特徵萃取

蒐集完畢的貼文資料為非結構化的自然語言文本, 因此在進行進一步量化分析前, 需經過一系列自然語言處理的前處理與特徵工程流程。此步驟的主要目標為:將語意層次的資訊(如情緒、主題、語氣)與格式表現(如 emoji、標點、媒體使用等)轉換為結構化欄位, 使後續分析得以有效識別與學習。將依據下列處理步驟進行:

### 1.1 文本清理(Text Cleaning)

首先將貼文中的噪音內容加以剔除, 包含:無意義的特殊符號與重複字元、多餘的標籤(如 #ad、#threads)、網址與超連結(避免干擾詞頻統計)、空白與格式錯誤修正, 能助於提升斷詞與語意判斷的準確性。

### 1.2 Emoji 標準化

由於 Threads 為 Z 世代使用者活躍平台, emoji 使用相當頻繁, 因此我們將建立 emoji 對照表, 將其轉換為文字描述(如 😞 → sad face), 且將統一格式化, 便於後續統計與機器辨識 emoji 在情緒傾向與貼文風格分析。

### 1.3 語言偵測與斷詞處理

由於 Threads 貼文中可能夾雜中英混用情況, 我們將使用語言識別模型判斷貼文語言屬性, 並根據語言分別使用適當的斷詞工具(如 jieba、spaCy 等), 並自訂門檻為 30 %: 若「漢字數 / 字元總數」 $\geq 0.3$ , 直接標記為中文。

### 1.4 情緒分析(Sentiment Analysis)

情緒傾向可能影響使用者互動意願, 我們將導入預訓練情緒模型或公開 API, 對每篇貼文進行情緒分類, 例如:

- 正向(例如:快樂、讚賞、感激)
- 中性(例如:陳述事實、新聞摘要)
- 負向(例如:抱怨、批評、悲傷)

### 1.5 主題標註與初步分類

為主題建模預作準備, 我們將以半自動方式判斷貼文是否具有明確主題, 如:社會議題、生活分享、感情觀察、娛樂評論等 此標記將作為 LDA、BERT 等主題模型的訓練基礎。

### 1.6 結構性特徵欄位建立

貼文的結構表現也可能與擴散效果相關, 我們將針對以下特徵進行量化紀錄:

- 是否使用問號、驚嘆號等情緒性標點、emoji 出現數與密度
- 是否附有圖片、影片、標註其他帳號(@)、包含 hashtag 或外部連結

## 二、向量化與模型建構

在完成初步的文字前處理與特徵萃取後, 我們將進一步使用自然語言處理工具, 將貼文內容轉換為可用於統計建模與機器學習分析的數值向量。這一階段的目標是將語意資訊系統化表示, 使其能夠與其他結構性變項共同納入模型進行推論。預計採用以下兩種主要向量化技術:

- TF-IDF 向量化:計算每個詞彙在貼文中出現的重要程度, 並根據其在整體語料庫中的稀有性進行加權, 能有效捕捉關鍵詞在單篇貼文中的代表性。

- BERT 向量嵌入:透過預訓練的語言模型(例如 Huggingface Transformers 或其他 API 提供之模型), 獲取每篇貼文的上下文語意表示, 使模型能辨識語境變化與潛在語意層次, 提升後續分析的準確度。

完成向量化後, 將進行以下統計與機器學習分析, 以驗證不同特徵與貼文擴散效果之間的關係:

- 邏輯／線性回歸分析:透過迴歸模型探討個別變項(如 hashtag 使用頻率、情緒傾向、emoji 出現頻率)對貼文觀看數之預測力, 並可進一步以「是否超過一萬觀看數」作為二元因變項進行迴歸建模。
- 主題分析與聚類:
  - 採用 LDA(潛在狄利克雷分配)進行無監督主題建模, 識別出貼文內容中潛在的語意主題分群;
  - 結合 K-Means 或 KNN 等聚類方法, 分析高流量貼文在主題分布或表現形式上是否具有共通樣貌, 進而歸納其內容輪廓。
- 多重共線性與自變項檢查:為確保模型穩定性與推論效力, 我們將檢查各自變數之間是否存在多重共線性或自我相關問題, 並視情況導入正規化技術(如 LASSO)以減少模型過擬合風險。

透過上述建模程序, 本研究得以在語意與統計層面雙軌並進, 深入揭示不同貼文特徵對其流量表現的實際影響。

### 三、AI 模型與 API 驗證

在完成統計模型與主題分析後, 我們進一步導入大型語言模型進行輔助驗證, 以補強分析結果的解釋性與語義面向的深度。本研究擬透過 GPT 類型的語言模型, 進行自動化文本摘要與語意聚合分析, 嘗試從語用層面探索高流量貼文中隱含的內容結構與風格特色, 並與統計模型所得結果相互印證。

- 常見寫作模式辨識:利用 GPT API 對高觀看數貼文進行摘要與分類, 觀察其是否具備特定寫作語氣、敘述邏輯或段落結構, 例如敘事體、開放式提問、幽默語調等。
- 觀點立場分析:辨別貼文內容為主觀陳述(如分享個人經驗、情緒抒發)或客觀資訊(如轉載新聞、資訊整理), 並探討其與觸及率之關聯。
- 主詞使用模式檢視:觀察是否使用「我」、「我們」等第一人稱主詞, 以及其頻率與句構, 推測個人化語氣是否有助於提升貼文的擴散性。

透過上述 LLM 模型生成之語意總結與風格識別結果, 我們將比對其與統計模型(例如回歸結果)與主題分析模型(LDA、BERT)所揭示的趨勢是否一致, 藉此檢驗分析結果的穩定性與整體邏輯一致性。此步驟不僅有助於補足量化模型無法觸及的語義差異與風格細節, 亦能提升研究

結論的可信度、可詮釋性與實務應用價值，對未來自媒體創作者或行銷策略制定提供更具可操作性的參考依據。

## Actual Research Processing

### 一、研究架構與技術工具

#### 1.1 資料處理與數值運算模組

本研究採用Python生態系統進行資料處理與分析，主要運用pandas套件進行結構化資料的讀取、清理與統計分析，並結合numpy進行高效能矩陣運算與數值處理。為確保與深度學習框架的相容性，本研究採用Hugging Face datasets.Dataset格式作為標準化資料結構，該格式提供類似pandas DataFrame的操作介面，同時支援大規模資料集的記憶體優化處理。

#### 1.2 自然語言前處理技術

本研究針對中文社群媒體文本特性，採用jieba分詞工具進行中文斷詞處理。為處理網路文本中的特殊字符與格式，運用正規表示式(Regular Expression)進行文字過濾、特徵擷取與格式標準化。考量社群媒體文本中emoji表情符號的情感表達功能，整合emoji套件進行表情符號的識別與分析。

文本向量化處理採用 TF-IDF (Term Frequency-Inverse Document Frequency)與詞頻統計(Count Vectorization)兩種方法進行文本向量化，以TfidfVectorizer與CountVectorizer分別實現詞彙重要性加權與基礎詞頻統計功能。

#### 1.3 多語言偵測與時間處理系統

建構雙層語言偵測機制，結合langdetect基礎偵測工具與Lingua進階語言識別系統。Lingua語言偵測器透過LanguageDetectorBuilder提供多語言支援、可配置語言範圍與高精確度識別能力。時間處理採用datetime與pytz套件，實現跨時區時間格式轉換與標準化處理。

#### 1.4 機器學習建模框架

採用scikit-learn機器學習套件建構實驗框架，運用train\_test\_split進行資料集劃分，以支援向量機(Support Vector Classifier, SVC)作為基準分類器。透過LabelEncoder實現類別標籤的數值編碼轉換，並運用classification\_report與accuracy\_score等評估指標進行模型效能量化分析。

## 1.5 深度學習與預訓練語言模型

採用PyTorch深度學習框架與Transformers套件，透過AutoTokenizer與AutoModel介面載入預訓練語言模型(如BERT系列)。此架構支援模型微調(Fine-tuning)與推論(Inference)作業，為後續深度學習實驗提供技術基礎。

## 二、語言偵測演算法設計

### 2.1 多階段語言識別機制

本研究開發出 `detect_lang_with_preprocessing_lingua` 函數，以實現多階段語言偵測流程，各階段任務分述如下：

第一階段為初始化與異常處理，透過建構 Lingua 語言偵測器並預載所有支援的語言模型，系統得以快速應對多語輸入。在處理資料前，會先針對空值 (NaN) 與空字串進行異常處理，並統一標記為 "unknown"，以避免後續分析出現錯誤。

第二階段為文本前處理，進行系統性的清理作業。這包括移除所有 URL 連結(如 http 或 https 協定)、過濾社群媒體常見標記(如 @username 與 #hashtag)、清除 emoji 表情符號，並將不必要的空白字符與換行符號加以標準化，確保語言模型能夠聚焦於真正有意義的語言特徵。

接著進入第三階段，中文特徵判定。系統會計算清理後文本中中文字符所佔比例，若超過 30% 的預設閾值，即可直接將該文本歸類為中文(標記為 "Ch")，以提升模型效率並減少誤判。

最後的第四階段為多語言識別。系統將運用 Lingua 演算法進行語言判定，其中中文的原始識別代碼(ZH)會轉換為「Ch」標籤以保持一致性，其餘語言則以 ISO 639-1 的標準兩碼小寫代碼表示。若遇到無法識別的案例，則統一標記為 "unknown"。此流程確保文本能被準確地分類，有助於後續的語言特性分析與模型訓練。

## 三、資料清理與特徵工程

### 3.1 數值欄位標準化處理

實施系統化數值欄位清理程序，處理社群媒體平台常見的數值格式變異：

千分位逗號格式("1,234")轉換為整數

中文數量單位("2.5萬")換算為數值(25,000)

適用欄位包含：按讚數(like\_count)、觀看數(view\_count)、分享數(share\_count)、轉發數(repost\_count)、回覆數(reply\_count)



### 3.2 布林變數二元化

將原始二元分類資料("Y"/"N")標準化為布林值(True/False), 適用於媒體內容標記欄位: 是否包含圖片(has\_photo)、是否包含影片(has\_video)。

### 3.3 表情符號特徵萃取

開發emoji特徵萃取模組, 從文本內容中識別並統計表情符號使用情況: 萃取所有emoji字符並進行字串串接(emojis欄位), 計算表情符號總使用頻次(emoji\_count欄位)。

### 3.4 時間特徵解構

實施時間維度特徵工程, 將時間戳記解構為多個時間特徵:

時區標準化: 轉換至台北時區(UTC+8)

時間格式化: 產生標準時間字串表示

週期特徵: 擷取發文星期(post\_weekday)與小時(post\_hour)

### 3.5 高流量貼文標記

建立高流量內容識別機制, 以觀看數10,000次為閾值, 建立二元病毒式傳播標記(viral)。

### 3.6 標點符號語言學特徵

分析文本中的標點符號使用模式, 建立語言學特徵變數:

疑問句標記(has\_question): 檢測問號使用

感嘆句標記(has\_exclaim): 檢測驚嘆號使用

## 四、多模態情感分析框架

本研究中我們提出一套多模態情感分析框架, 以因應社群貼文中跨語言與多樣化表徵的挑戰。此框架整合了預訓練語言模型、表情符號資訊與語言強度特徵, 實現更為精準且語境敏感的情感分類機制。

### 4.1 預訓練模型配置

首先, 在預訓練模型配置方面, 我們建構了一套雙語情感分析系統, 分別針對中英文語料選用效果最佳的語言模型。英文情感判讀採用專為社群語境優化的

cardiffnlp/twitter-roberta-base-sentiment, 而中文部分則選用 uer/roberta-base-finetuned-jd-binary-chinese, 該模型具備良好的中文語義理解能力, 能有效掌握貼文中的情感傾向。

## 4.2 情感分類演算法

為了靈活應對語言變異, 我們進一步設計了 `classify_transformer_sentiment` 函數, 實作具備語言辨識能力的情感分類演算法。根據貼文的語言識別結果, 系統自動切換對應模型, 並回傳包含情感標籤與信心分數的預測結果。對於中性語句或模型無法有效辨識的文本, 預設回傳標準中性組合 ("neutral", 0.5), 以保持分析結果的一致性與保守性。

## 4.3 多模態情感校正機制

為提升情感偵測的敏感度與準確率, 我們進一步引入多模態情感校正機制。透過 `adjust_sentiment_by_emoji` 函數, 模型能整合表情符號與語言表現進行情感微調。具正向意涵的 emoji (如 😄、😍) 會上調分數 +0.1, 而具負面情緒的 emoji (如 😡、💀) 則會下調 -0.2; 此外, 語言中若出現強調情緒的特徵 (如超過兩個驚嘆號或使用「超」等強化詞彙), 系統亦會進行微幅調整 (+0.05), 以反映語者的情緒強度。整體情感分數最終會限制在 [0.0, 1.0] 的有效範圍內, 確保數值穩定。

## 4.4 情感分數標準化與標籤化

在情感分數標準化與標籤化階段, 我們實作 `get_sentiment_score_and_label` 函數, 將模型信心分數映射至統一的情感強度刻度。對於正向情感, 最終分數為 0.5 加上置信值的一半; 負向則為 0.5 減去一半置信值; 中性情感則固定為 0.5。根據此標準化結果, 情感分類被明確分為三類: 分數大於 0.66 視為正向, 小於 0.33 判定為負向, 介於其間者則歸為中性。

# 五、人稱視角分析系統

我們也透過人稱視角分析系統, 探討社群貼文中敘事觀點的差異與潛在影響。該系統主要包含人稱代詞的識別演算法與人稱特徵的衍生變數建構兩大核心模組。

## 5.1 人稱代詞識別演算法

在人稱代詞識別演算法部分, 我們開發了 `detect_person_view` 函數, 用於解析貼文中的敘事視角。此方法基於人稱關鍵詞的出現情形進行判斷。

我們定義三種基本人稱類別: 第一人稱包括「我」、「我們」、「I」、「we」; 第二人稱涵蓋「你」、「你們」、「you」; 而第三人稱則包括「他」、「她」、「他們」、「她們」、「he」、「she」、「they」、「them」。

- 第一人稱: 我、我們、I、we

- 第二人稱:你、你們、you
- 第三人稱:他、她、他們、她們、he、she、they、them

依據這些關鍵詞在文本中出現的組合情況，系統可將貼文歸類為單一人稱(例如僅包含第一人稱則標記為 "1st")、混合人稱(如同時出現第一與第三人稱，標記為 "mixed")，或無人稱(即未偵測到任何人稱代詞，標記為 "none")。

- 單一人稱:僅包含特定人稱("1st"/"2nd"/"3rd")
- 混合人稱:同時出現多種人稱("mixed")
- 無人稱:未檢測到任何人稱代詞("none")

## 5.2 人稱特徵衍生變數

為了強化後續統計模型的解釋力與特徵工程，我們建構了一組人稱特徵衍生變數。這些變數以二元邏輯表示，分別對應是否包含某一類人稱。具體來說，has\_1st 表示貼文是否含有第一人稱(無論是純第一人稱或混合型)，has\_2nd 和 has\_3rd 則分別代表是否涉及第二與第三人稱。這些衍生特徵可作為模型輸入，協助分析不同人稱視角對貼文瀏覽量、互動率或情感傾向的潛在影響。

- has\_1st:是否包含第一人稱(含混合類型)
- has\_2nd:是否包含第二人稱(含混合類型)
- has\_3rd:是否包含第三人稱(含混合類型)

# 六、深度學習模型架構

## 6.1 FusionMacBERT基礎融合模型

採用直接特徵融合策略，將BERT編碼器的[CLS]標記輸出，數值的部分則是先做embedding，並將兩者拼接過線性分類器，透過全連接層實現多模態特徵整合與分類預測。此架構代表最簡化的特徵融合方法。

## 6.2 MacBERTWithGRU序列增強模型

在BERT基礎上整合雙向門控循環單元(Bidirectional GRU)，透過序列建模捕捉文本的長期依賴關係。GRU層接收BERT的完整序列輸出，提取時序特徵後與數值特徵融合，適用於需要強化序列資訊的分類任務。

### 6.3 MacBERTMLPFusion深度融合模型

採用多層感知機(Multi-Layer Perceptron)實現深度特徵融合, 將BERT輸出與直接與數值特徵輸入多層全連接網路。網路架構包含ReLU激活函數與Dropout正規化機制, 透過非線性變換學習複雜的特徵交互模式。

### 6.4 TextCNNMacBERT卷積增強模型

整合一維卷積神經網路(1D-CNN)與BERT編碼器, 採用多尺度卷積核(kernel size: 2, 3, 4)提取局部文本特徵。卷積層輸出經最大池化操作後與數值特徵融合, 適用於捕捉文本局部語義模式的分類任務。

## 七、延伸嘗試 - 利用 LIME、SHAP 找尋重要特徵

在本研究的延伸嘗試中, 我們引入了兩種模型可解釋性技術——LIME 與 SHAP, 藉此探索預測模型中各項特徵對觀看數預測的實際貢獻與重要性, 進一步檢驗深度模型運作的邏輯。

### 7.1 特徵重要性與貢獻分析- LIME

在 LIME (Local Interpretable Model-agnostic Explanations) 部分, 我們運用其「局部模擬解釋」的原理, 針對特定樣本建立近鄰資料點, 並觀察模型預測如何隨輸入微調而變化。具體而言, 我們以 LimeTabularExplainer 對訓練好的 MLP 模型進行分析, 將 BERT 語意向量與數值特徵融合後送入解釋器。

舉例來說: 當模型預測某篇 Threads 貼文將獲得高觀看數時, LIME 會對其內容進行輕微擾動(如替換用詞或調整時間特徵), 觀察這些改動對預測結果的影響, 藉此推估哪些特徵對於提升觀看數扮演了關鍵角色。例如, 「使用第一人稱」、「出現『生活』或『感謝』等正面詞彙」常與高觀看數正相關。透過這類局部分析, 我們可深入了解模型在單一預測決策上的依據。

### 7.2 特徵重要性與貢獻分析- SHAP

在 SHAP (SHapley Additive exPlanations) 的應用中, 我們著重於全體樣本的整體特徵貢獻分析。SHAP 基於合作博弈理論, 將模型輸出拆解為每個特徵對預測結果的「貢獻值」, 有助於理解整體模型的偏好與關注點。

相較於 LIME 偏向局部樣本的解釋, SHAP 更適合用來觀察哪些特徵對「整體樣本族群」都具關鍵影響。分析結果顯示, 不同模型架構對特徵的重視程度略有差異: CNN 結構傾向依賴人稱與互動行為等結構特徵; 深層 MLP 模型則較重視 emoji 使用、情緒強度與語意互動等維度; GRU 架構則對「轉發行為」、「驚嘆號」等情緒強度特徵表現出高度敏感; 至於 FusionMacBERT 模型, 則明顯偏好貼文結構性特徵, 如文章長度、是否包含網址等。

## Research Result

### 一、回歸模型

回歸式如下所示，以下式子已剔除未顯著之變數，未顯著之變數包含 `has_question` 是否有問號、`has_url` 是否有網址、`has_mention` 是否@提及他人、`sentiment_score` 情緒分數、`person_view_encoded` 文章視角)：

$$\begin{aligned} \text{view\_count} = & -14.66 \times \text{repost\_count} - 3875 \times \text{sentiment\_score} \\ & - 792.96 \times \text{emoji\_count} + 2589 \times \text{has\_photo} + 3691 \times \text{has\_video} - 20.43 \times \text{content\_length} \\ & + 7189 \times \text{has\_exclaim} - 13350 \times \text{has\_hashtag} + \varepsilon \end{aligned}$$

一共十三個回歸自變數中，有八個顯著變數，五個不顯著變數。顯著變數主要與貼文互動行為(like、reply、share)、媒體形式(圖片、影片)、內容特徵(emoji 數量、驚嘆號、有無 hashtag、貼文長度)有關。

#### 1.1 顯著影響因素 ( $p < 0.05$ )

OLS 回歸結果顯示，不同的貼文特徵對觀看數具有顯著且方向各異的影響。首先，互動性指標普遍與觀看數呈正向關係，例如每獲得一個 like 能帶來約 9.25 次的額外瀏覽量，而每一則留言的效果更為顯著，能提升約 38 次瀏覽量。分享的影響力亦不容忽視，每多一次分享可增加約 23 次觀看數，顯示貼文的擴散效果有助於觸及更多觀眾。

在媒體內容方面，圖片與影片的加入大幅提升流量。每多一張照片可帶來 5,548 次的觀看量，符合圖片具有高度吸睛效果的預期。而影片的效果更為明顯，一部影片可帶來約 42,900 次的額外觀看數，是所有變數中影響力最強的項目。此外，語氣強烈的符號例如驚嘆號，也能引發觀眾注意，每多一個驚嘆號平均帶來近 11,970 次的觀看提升。

變數	影響	係數(coef)	解釋
has_photo	正面	+2589	帶圖片貼文平均多 2.6k 瀏覽
has_video		+3691	影片貼文平均多 3.7k 瀏覽
has_exclaim		+7189	有驚嘆號可大幅提升瀏覽量
sentiment_score		-3875	情緒分數越高反而瀏覽量下降
emoji_count	負面	-792.96	emoji 用越多，瀏覽數顯著下降
repost_count		-14.66	每多一次轉發，反而減少 15 次瀏覽
content_length		-20.43	內容越長略微降低瀏覽，每多約 20 字減少一次
has_hashtag		-13350	加 hashtag 會顯著減少曝光量，可能因為平台演算法

某些看似增加表達豐富度的元素卻可能對觀看數產生負面影響。例如 emoji 雖為表情符號，但每多用一個反而減少 793 次觀看數，可能是因為過度使用使貼文顯得凌亂或降低專業感。同樣地，轉發次數對觀看數竟為負相關，每次轉發平均減少 15 次瀏覽量，或許與平台演算法偏好原創內容有關。更令人意外的是，有使用 hashtag 的貼文平均觀看數反而下降了 13350 次，顯示 hashtag 並不一定能提升觸及率，甚至可能被演算法判定為行銷內容而限縮曝光。此外，因為每多一個字平均會使觀看數下降 20.43，所以文字數量亦需控制，顯示長篇文字可能導致觀眾流失。因此，撰寫貼文時應朝簡潔有力的方向調整，結合圖片或影片媒材，並著重鼓勵用戶留言與分享，以最大化觀看數效益。

此外，在情緒分數影響方面，可以看見情緒分數愈高，瀏覽量反而會下降。除了回歸分析本身的偏差外，或許「正向過頭、太正面的貼文內容在 Threads 上反而較不吸引人觀看」。相反地，這代表「較負面的內容可能更吸引此平台上的用戶觀看」，對於想要獲得高瀏覽量的人來說，這是本組的一大發現。

### 1.2 未顯著影響因素 ( $p > 0.05$ )

部分變數雖然直覺上可能對觀看數有所影響，卻未達統計顯著水準，表示它們在預測曝光度上效果有限。像是帶有問號的貼文 (has\_question) 對觀看數並無明顯助益，可能是因為問號本身僅表示語氣或句型，並不一定引導觀眾參與討論或互動，觀眾或演算法可能更重視內容本身的品質，而非語言形式。

貼文中是否包含外部連結 (has\_url) 也未顯著影響曝光，可能是因為帶有網址的貼文經常被平台視為導流內容，進而被限制觸及；另一方面，觀眾也可能因為不願離開平台，而對這類貼文興趣不高，因此無法有效提升觀看數。

提及他人帳號 (has\_mention) 同樣未在模型中呈現顯著效果。這可能與 tag 對象是否為高關注帳號有關，若提及的是互動度不高或非公眾人物，則其對貼文曝光的實質影響有限。此外，僅標註他人並不代表會產生互動，若未形成對話或互相轉發，影響力將非常有限。

人稱視角 (person\_view\_encoded) 在此模型中也未產生顯著貢獻。雖然從第一人稱或第二人稱視角撰寫可能影響語氣的親密程度，但這樣的語言風格對觸及範圍的影響可能並不直接，也未必符合平台演算法的偏好，若僅依據人稱視角並不足以預測觀看數的變化。

變數	說明
has_question	問號對串文曝光度無明顯影響
has_url	串文是否帶網址，對曝光無顯著關聯
has_mention	提及他人 tag 他人的文章，對曝光不顯著
person_view_encoded	人稱視角 (1st/2nd/3rd) 在這個模型中不顯著

## 二、預測建模

### 2.1 MLP 模型訓練與預測

除了針對爬取的串文進行 OLS 回歸分析，我們也進一步導入多層感知機(MLP)模型，嘗試預測每則串文的觀看數級距，作為後續自動化預測與優化內容策略的依據。下表為

TextCNNMacBERT、MacBERTWithGRU、FusionMacBERT、MacBERTMLPFusion 四大模型的重點處理目標與優缺點分析：

模型名稱	重點處理目標	文字處理	優點	缺點
TextCNNMacBERT	融合語意與結構特徵	使用 BERT [CLS] 向量，與數值特徵 concat，一起餵進分類器	同時利用語意 + 結構特徵表現穩定、實作簡單	若語意資訊、結構資訊其中一品質不好，可能干擾預測效果
MacBERTWithGRU	時序上下文 (全局語境)	GRU 讀 BERT 的每個時間步	模擬時序、序列的記憶、比較省參數	訓練慢、比 CNN 慢 泛化力下降
FusionMacBERT	特徵互動 (向量拼接)	直接拼接 CLS 向量與數值特徵 → 多層全連接層 (MLP)	可學非線性關係、簡單、泛化強	易過擬合，沒有時間資訊，無法捕捉詞序
MacBERTMLPFusion	關鍵片語 (局部模式)	CNN對BERT輸出做卷積	抓出 N-gram 式的局部資訊	無法捕捉長距離語意關係中庸類別常被忽略

在本次模型訓練中，針對數值特徵進行了標準化處理。具體而言，將每個數值特徵轉換為平均值為 0、標準差為 1 的常態分布形式。此舉有助於將原本尺度差異懸殊的特徵(例如 emoji 數、字數或影片觀看次數)調整至相似範圍，避免某些數值範圍特別大的特徵對模型學習造成不當影響。此外，標準化也能提升模型訓練的穩定性，加速收斂過程，對多層感知機(MLP)等依賴梯度優化的模型尤其重要。

為了進行多類別分類，本研究根據每篇貼文的瀏覽量(view\_count)設定了四級標籤。瀏覽量低於 1,000 定義為「low」；1,000 至 10,000 為「medium」；10,000 至 100,000 為「high」；而超過 100,000 的則歸類為「very high」。這樣的分級設計能夠更細緻地刻畫不同等級的曝光程度，並使分類模型具備辨識高瀏覽數內容的能力。

考量到四類標籤之間的資料不均衡問題，特別是「very high」與「low」兩類資料量明顯較少，本研究採用了 Oversampling 技術，透過複製這些少數類別的樣本以增加其在訓練集中的比例。同時，為了進一步強化模型對於困難樣本的學習效果，亦輔以 WeightedRandomSampler 或 FocalLoss 等方法，提升模型在處理少數類別與誤判樣本時的敏感度與準確率。這些手段共同提升了模型在類別不均情況下的表現穩定性與預測能力。

## 2.2 模型報表

四大模型分別為TextCNNMacBERT、MacBERTWithGRU、FusionMacBERT、MacBERTMLPFusion, 模型報表如下：

模型名稱	準確率	Macro Avg F1-Score	Weighted Avg F1-Score	模型架構特色
TextCNNMacBERT	0.76	0.55	0.71	BERT + CNN卷積 + 數值特徵
MacBERTWithGRU	0.64	0.59	0.67	BERT + 雙向GRU + 數值特徵
FusionMacBERT	0.75	0.63	0.75	BERT + 直接特徵融合
MacBERTMLPFusion	0.71	0.58	0.71	BERT + MLP深度融合

TextCNNMacBERT 表現最佳, MacBERTWithGRU 在 Very High 類別的識別上表現突出 (F1=0.91)

FusionMacBERT 雖然整體準確率略低, 但加權 F1 分數最高 (0.75), 表示在處理不平衡數據時更加穩定。MacBERTMLPFusion 通過深層 MLP 進行特徵融合, 但在某些類別 (如High) 上表現較弱。

	Low			Medium			High			Very High		
	P	R	F1	P	R	F1	P	R	F1	P	R	F1
TextCN NMacBE RT	0.79	0.96	0.87	0.51	0.18	0.27	0.44	0.18	0.26	0.76	0.89	0.82
MacBER TWithG RU	0.91	0.66	0.76	0.33	0.73	0.46	0.32	0.20	0.24	0.93	0.89	0.91
FusionM acBERT	0.86	0.86	0.86	0.44	0.54	0.49	0.38	0.21	0.27	0.89	0.89	0.89
MacBER TMLPFu sion	0.86	0.80	0.83	0.38	0.58	0.46	0.31	0.09	0.14	0.89	0.89	0.89

## 2.3 關鍵發現

在本次多類別預測任務中, TextCNNMacBERT 模型表現出最優異的整體準確率, 達到 76%, 顯示其在整體分類能力上具有穩定性與可靠性。而在加權 F1 指標方面, FusionMacBERT 則以 0.75 脫穎而出, 顯示其在各類別間達成更均衡的預測表現。針對「Very High」高瀏覽量類別, MacBERTWithGRU 的表現尤為突出, F1 分數高達 0.91, 顯示其在處理高曝光內容的特徵時具備優勢。



在「Low」低瀏覽量類別的識別方面，所有模型均展現穩健的效果，F1 分數皆超過 0.76，代表該類別特徵相對清晰，分類較為容易。然而，在「High」與「Medium」這兩個中段類別上，整體表現仍有待提升，多數模型在這些類別的預測準確性明顯偏弱，可能與樣本交界模糊或特徵不明顯有關，未來需針對此部分進一步優化。

綜合模型表現與應用情境考量，若應用目標著重於整體預測準確性，建議選擇 TextCNNMacBERT；若更重視各類別間的平衡性與泛化能力，則 FusionMacBERT 為更合適的選擇。未來亦可針對難分類別進行資料強化或特徵精煉，以提升整體模型效能。

- 最佳整體準確率:TextCNNMacBERT (76%)
- 最佳加權F1:FusionMacBERT (0.75)
- Very High類別表現最佳:MacBERTWithGRU (F1=0.91)
- Low類別識別能力:所有模型在此類別都有不錯表現(F1>0.76)
- 挑戰類別:High和Medium類別普遍表現較差，需要進一步優化
- 模型選擇建議:根據應用場景，TextCNNMacBERT適合追求整體準確率，FusionMacBERT適合平衡各類別表現

## Research Attribution

### 一、學術價值

本研究以新興社群平台 Threads 為研究場域，探討貼文內容特徵與其擴散成效之間的關聯，具有多層次的學術貢獻。首先，Threads 作為由 Meta 推出的文字導向社群平台，其平台設計以簡化的互動結構(如取消分享次數可視化、取消按讚數排序)與強調即時對話性為主要特色，與傳統社群平台如 Facebook、Instagram 或 TikTok 呈現出明顯差異。然而，當前相關文獻仍多聚焦於傳統平台的演算法操控、社會網絡圖譜分析與影音內容演算模式，對 Threads 這類以文字、主觀情緒與匿名互動為主體的傳播場域討論相對匱乏。因此，本研究有助於填補平台間異質性對內容擴散機制之影響的研究空白，並為未來跨平台比較分析奠定實證基礎。

其次，社群研究領域正逐漸從過去強調名人與權威帳號的傳播力，轉向對「素人內容」與「去中心化影響力」的關注。本研究特別選擇無認證素人帳號的資料作為樣本，觀察其內容屬性如何影響自然瀏覽量與互動率，有助於回應當代社會中對於「誰能創造影響力」的深層提問。特別是當權力與話語權日益去中心化的趨勢下，本研究所呈現的結果有助於重新建構數位公共領域中「注意力經濟」的分配機制與邏輯。

再者，本研究運用機器學習與自然語言處理技術(如情緒分數分析、句長計算、結構標記等)，從內容特徵進行量化，結合回歸模型與可視化分析，提升社群文本研究的可重現性與方法論嚴謹性，也讓傳播研究在質性與量化之間有了更具整合性的實踐路徑。此一方法論架構未來亦可延伸應用於其他平台或語言場域，對數位人文與社會科學交叉研究具高度參考價值。

## 二、產業價值與實務應用

在產業層面，本研究結果預期可廣泛應用於數位行銷、社群經營、內容策略與創作者輔助工具的開發等多元場域，具有高度實務價值。對於中小企業或個人創作者而言，在資源有限、競爭激烈的數位環境中，若能依據本研究揭示之內容特性調整貼文策略，便有機會有效提升自然觸及與用戶互動，進而降低對廣告投放的過度依賴，達成資源最佳化配置。

具體而言，本研究回歸分析顯示：「越正向的文章反而越不吸引人、而負面語氣可能提升瀏覽量」，此一發現挑戰了傳統行銷中「正能量即帶來好感」的迷思，反映出使用者行為背後潛藏的「情緒驅動」與「情感引發點擊」的心理。創作者若能有意識地設計情緒語氣與敘事策略，不僅能提升內容的擴散力，也能在符合倫理與誠信的前提下，掌握「引發共鳴」的創作核心。

此外，本研究成果亦可作為 AI 創作輔助工具設計的理論基礎。未來可結合語意分析、內容生成與使用者行為預測模型，打造一套針對素人創作者、個人品牌經營者或中小商家量身訂製的「內容優化系統」。該系統可根據用戶輸入的貼文主題、自我定位與語言風格，提出如情緒強度、時間發文建議、標題長度、標籤設計等具體優化策略，實現智慧化社群經營。對品牌來說，也能藉此更準確評估貼文策略與觀眾心理之間的微妙連動，提高每篇貼文的投資報酬率(ROI)。

進一步地，若結合 A/B 測試平台與動態情緒監測系統，甚至可持續優化貼文實驗架構，形成一種「演化型內容策略」模式，使得數位行銷不再是憑感覺操作，而是以數據為基礎、用模型輔助決策的系統性流程。這對目前依賴社群流量維生的個體創業者、內容農場、小型品牌與地方行銷單位而言，無疑是一項可擴展的戰略資產。綜上所述，本研究在理論與實務兩端皆具獨特貢獻：不僅深化對文字型社群平台內容擴散機制的理解，也提供可實作的策略建議與應用框架，有潛力在學界與產業界之間架起有意義的橋樑。

## Reference

Singh A, Halgamuge MN, Moses B. An Analysis of Demographic and Behavior Trends Using Social Media: Facebook, Twitter, and Instagram. *Social Network Analytics*. 2019:87–108. doi: 10.1016/B978-0-12-815458-8.00005-0. Epub 2019 Jan 11. PMID: PMC7149696.

Reimer, T. (2023). Environmental factors to maximize social media engagement: A comprehensive framework. *Journal of Retailing and Consumer Services*, 75, 103458. <https://doi.org/10.1016/j.jretconser.2023.103458>.

Kolr (2023)。2024 年台灣社群網紅趨勢觀察報告 [簡報檔]。Google Drive. <https://drive.google.com/file/d/1SehPlpBB43EbgAW2Q7wwgk6xMFLiZd9H/view>

就是廣告科技股份有限公司(2023)。網紅定義是什麼？一篇詳細解析網紅意思與網紅行銷帶來的5大轉變。<https://www.just-adtech.com/influencer-definition/>

Zhiyu Jiang. The Rise of Nano-Influencers: Case Studies of Daniel Wellington, CeraVe, and Lush Cosmetics in Digital Marketing. *Academic Journal of Business & Management* (2025), Vol. 7, Issue 1: 173-180. <https://doi.org/10.25236/AJBM.2025.070123>.

K. Zarei et al., "Characterising and Detecting Sponsored Influencer Posts on Instagram," 2020 IEEE/ACM International Conference on Advances in Social Networks Analysis and Mining (ASONAM), The Hague, Netherlands, 2020, pp. 327-331, doi: 10.1109/ASONAM49781.2020.9381309.

Lin, H.-H., Lin, J.-D., Ople, J. J. M., Chen, J.-C., & Hua, K.-L. (2021). *Social media popularity prediction based on multi-modal self-attention mechanisms*. IEEE Access. <https://doi.org/10.1109/ACCESS.2021.3136552>

## Group Members and Division of Work

組員	學號	工作分配
劉姝豆	R12725045	文獻回顧 Threads 貼文爬蟲 上台簡報
黃浚棋	R13741019	文獻回顧 預期研究結果 上台簡報製作
張鈞傑	B10801011	文獻回顧 研究方法 資料前處理與回歸分析 神經網路模型訓練與預測 LIME 分析
卓庭榛	B11801004	文獻回顧 資料前處理與回歸分析 上台簡報 SHAP 分析